Reseau de neurones

Projet de ML

Cherchour Lièce
Thauvin Dao

Faculty of Science and Engineering
Sorbonne université

Contents

1 Travail effectué

Nous avons implementé la partie obligatoire du sujet et les différents modules basique nécessaire à un réseau convolutif. Nous avons de plus défini une fonction d'activation LeakyReLU, rajouté la possibilité d'avoir un biais pour le module linéaire et ajouté la possibilité de mettre des données de validation pour observer la précision au fur et à mesure des itérations. Nous avons effectué plusieurs types de tests pour être sur que nos différents modules marche bien. Pour les modules linéaire et convolutif nous avons créé des fichiers permettant de vérifier les différentes dimensions à plusieurs étapes. Pour le reste, nous avons crée des réseaux de neurones pour analyser les résultats que l'on obtenait en utilisant nos différents modules.

2 Réseau linéaire

Pour tester notre réseau linéaire, nous avons décider de générer des données à 2 attributs aléatoirement et utilisé une fonction linéaire bruité (sous la forme $a * x_1 + b * x_2 + c$) pour calculer les y de nos données (attribut à prédire).
Le but de notre réseau est donc de retrouver la fonction linéaire associé, il s'agit donc d'un problème de régression.
Nous utilisons seulement un seul neurone de sortie sans couche cachée pour notre réseau prenant x_1 et x_2 en entrée et renvoyant y.
En premier, nous utilisons 100 données en entrée avec un gradient step de $1e-4$ et 300 itérations.
Les résultats obtenus pour les poids sont :

	a	b	c
originaux	1002	13	4
obtenus	1002.01	13.00	3.85

Les différentes valeurs sont obtenues en récupérant les poids de notre neurone, on observe bien une correspondance avec les poids de notre fonction linéaire ce qui montre bien le fonctionnement de notre réseau.
Pour en être sur, regardons l'évolution de la loss au cours des itérations:

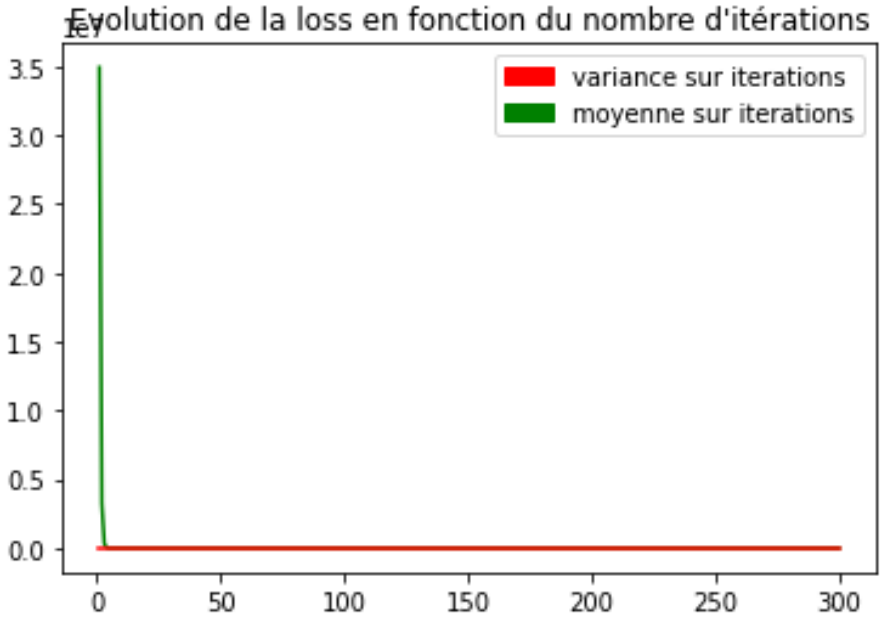

On observe que la loss diminue très peu après quelques itérations, essayons de faire seulement 50 itérations.
Résultats obtenus :

	a	b	c
originaux	1002	13	4
obtenus	1001.81	13.89	-4.74

Les résultats obtenues sont plutôt bon mais moins bon que lors de notre dernière itération surtout au niveau du biais. Les dernières itérations sont donc tout de même utile ici malgré la non évolution de la loss.

3 Réseau non-linéaire

Nous avons implémenté notre réseau linéaire et avons utilisé les données de **gen_arti, data_type=1** défini dans les TPs précédent pour tester notre réseau. Le but de notre réseau est de faire une classification des données **gen_arti, data_type=1**. Par la suite on va afficher la frontière de décision obtenues en 2D pour différents paramètres . Nous utilisons entre 2 et 5 neurones pour la partie cachée de notre modèle durant les tests, et nous comparons les solutions obtenues. En premier temps, nous avons un réseau avec 2 entrées (x_1 et x_2 d'une donnée) une partie cachée avec 3 neurones et notre couche de sortie qui n'en possède qu'un seul.

Nous allons donc faire varier le nombre de neurones et la tailles des batchs pour voir les différentes frontières de décision et évolution de la fonction de coût associé.

3.1 Résultat pour 2 neurones avec un batch_size = len(datax)

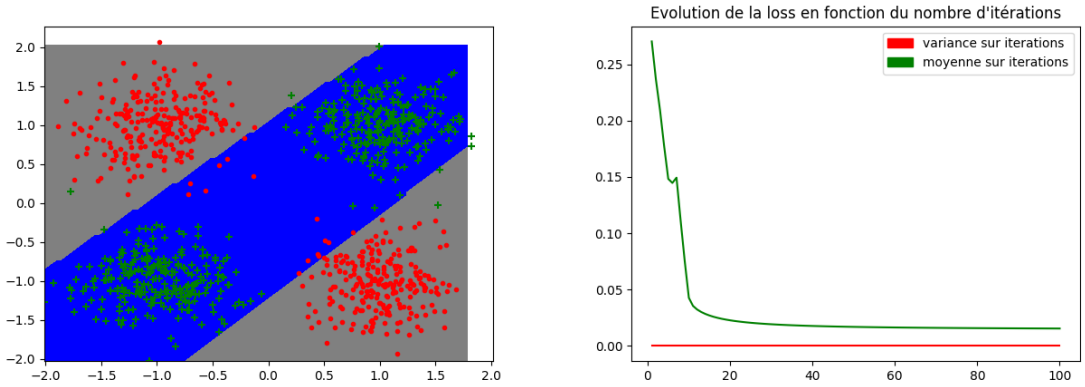

3.2 Résultat pour 3 neurones avec un batch_size = len(datax)

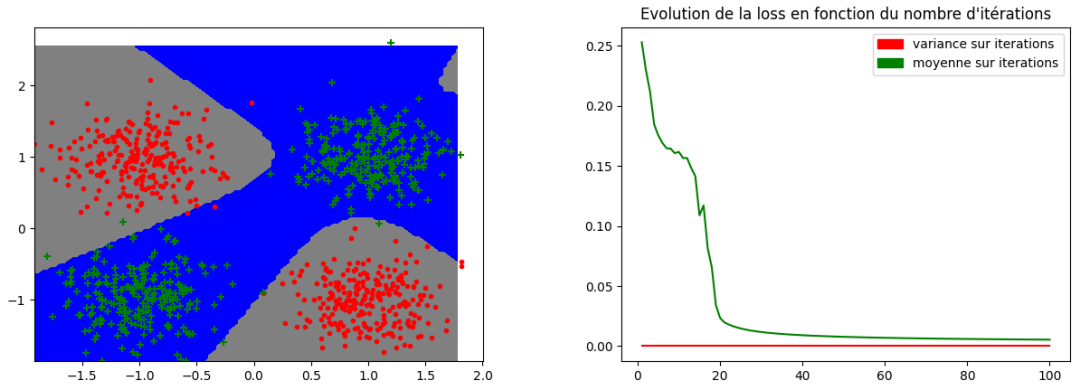

3.3 Résultat pour 5 neurones avec un batch_size = len(datax)

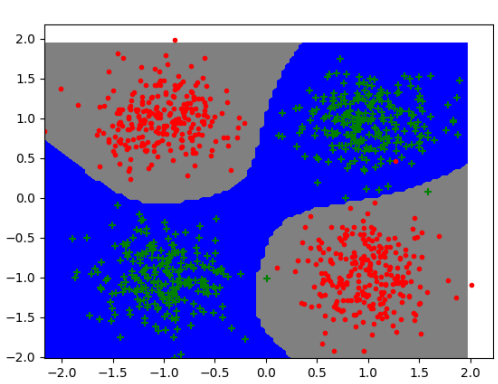

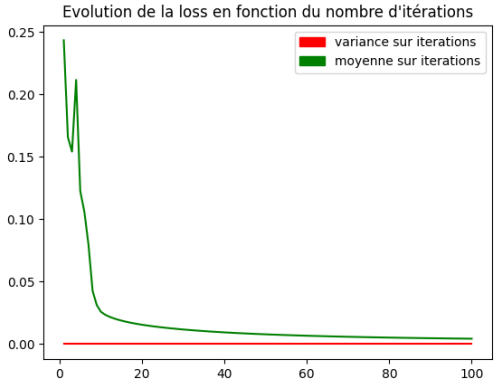

3.4 Résultat pour 3 neurones avec un batch_size = 100

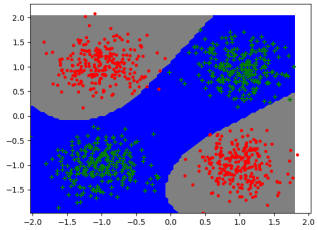

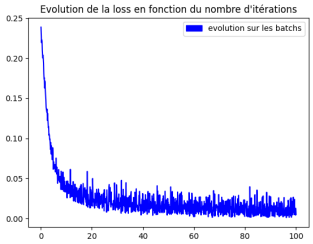

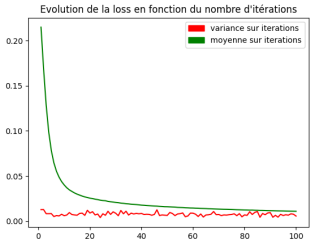

3.5 Observations

On observe que plus on ajoute de neurones cachées plus la frontière de décision obtenues est complexe, c'est assez logique car notre nombre de paramètres augmente. On observe également que pour 3 neurones, en changeant seulement la taille du batch, on obtient une frontière de décision légèrement plus lisse, mais une convergence bien plus rapide (environ 2 fois moins d'itérations).

4 Mise en place d'une pipeline

Notre pipeline permettant d'emboîter différents module indépendants entre eux est complètement opérationnelle et correspond à celui de l'énoncé. Nous avons ajouté un paramètre verbose à la fonction SGD, une verbose de 1 permet l'affichage de l'évolution du coût durant l'exécution et une verbose de 2 permet en plus d'ajouter l'affichage d'une courbe correspondante en fin d'itérations (avec une autre courbe qui fait de même mais en affichant les coûts des différents batch au lieu d'en faire une moyenne). De plus nous avons ajouté la possibilité de donner des données de validation pour vérifier l'évolution de la précision tout au long des itérations pour détecter le sur-apprentissage.

5 Mise en place du multi-classe

Pour le multi-classe, nous avons implémenté un réseau de la forme :
linear(input_size, hidden_size) -> Sigmoid() -> linear(hidden_size,10) -> Softmax
En utilisant un coût d'entropie croisée, une batch_size de 100 et un pas de gradient de $1e-3$. Nous avons fait varier la hidden_size de la couche cachée du réseau pour réaliser des observations.
Le but de ce réseau est de classé les nombres de la base USPS, bien sur nous faisons une séparation test/train.
Nos résultats :

Taille couche cachée	Précision
1000	0.90
128	0.91
100	0.90
50	0.89
10	0.88
5	0.84

Le nombre de neurones intermédiaires est un paramètres assez critique, effectivement entre choisir 128 neurones cachées ou 10, on obtient un temps d'exécution assez différents et des résultats meilleur lorsque le nombre de neurones est important. Mais on remarque également qu'au bout d'un moment, cela ne sert plus à rien d'ajouter des neurones intermédiaire.
Effectivement si l'on passe de 5 à 10 neurones cachées on observe une amélioration sur la précision de 4%, mais si l'on passe de 10 à 100 neurones, on observe une amélioration de à peine 1% et on pourrait se demander si le temps de calcul supplémentaire vaut vraiment le coup dans ce cas la.
Nous avons aussi testé une taille de couche cachée absurde de 1000 mais notre précision diminue assez peu (1%), sûrement dû à la simplicité du problème.

6 Auto-encodeur

Ici nous réalisons les tests avec 100 itérations, un batch size de 50, un gradient step de $1e-3$ des couches cachés de taille 100 et une compression de taille 10 quand cela n'est pas précisé.
Nous avons testé nos données sur deux jeux de données : USPS et MNIST. Mais nous avons décidé de présenter nos résultats sur le jeu de données USPS, le jeu de données étant plus petit, il est possible que les résultats soient meilleurs avec MNIST mais les calculs seraient plus lourds.
Bien sur nous faisons une séparation test/train pour les tests comme dans les parties précédentes.

6.1 Visualisation

Ici nous visualiserons les représentations obtenues après compréhension (en dernier dans nos images) et après reconstruction (en second dans nos images) en fonction du facteur de compression.

6.1.1 Compression de taille 10

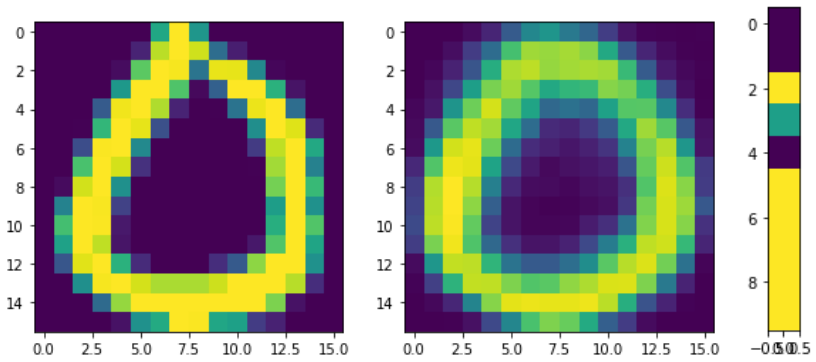

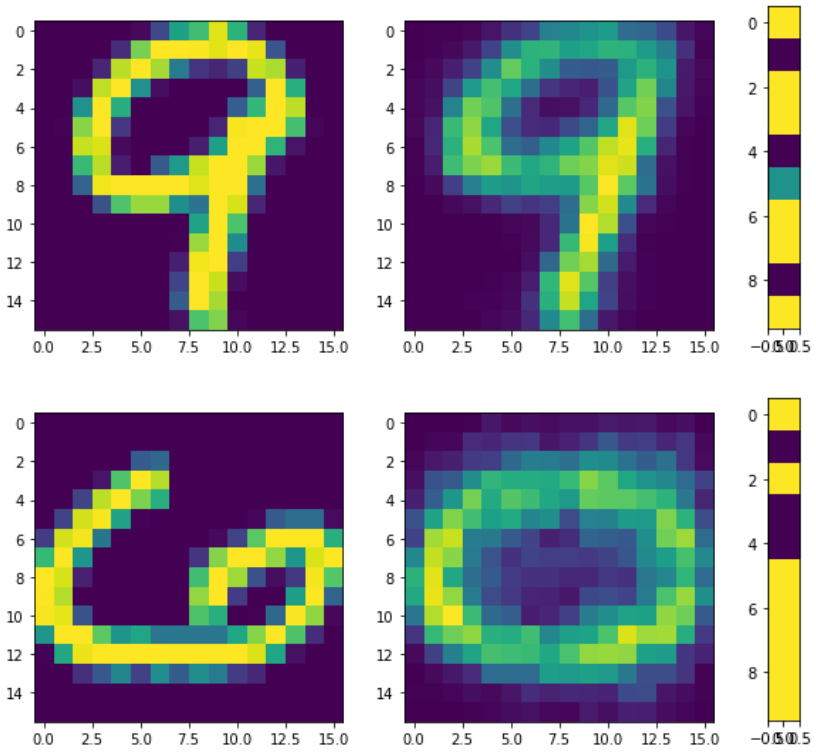

Ici on affiche un 0, un 9 et un 6. Il est déjà facile de voir que le 6 n'est pas reconstruit correctement, ça reconstruction correspond plus à un 0. On observe d'ailleurs que notre compression du 6 est très proche de la compression du 0 mais est plus éloigné du 9, ce qui correspond à notre observation sur la reconstruction obtenue.

6.1.2 Compression de taille 3

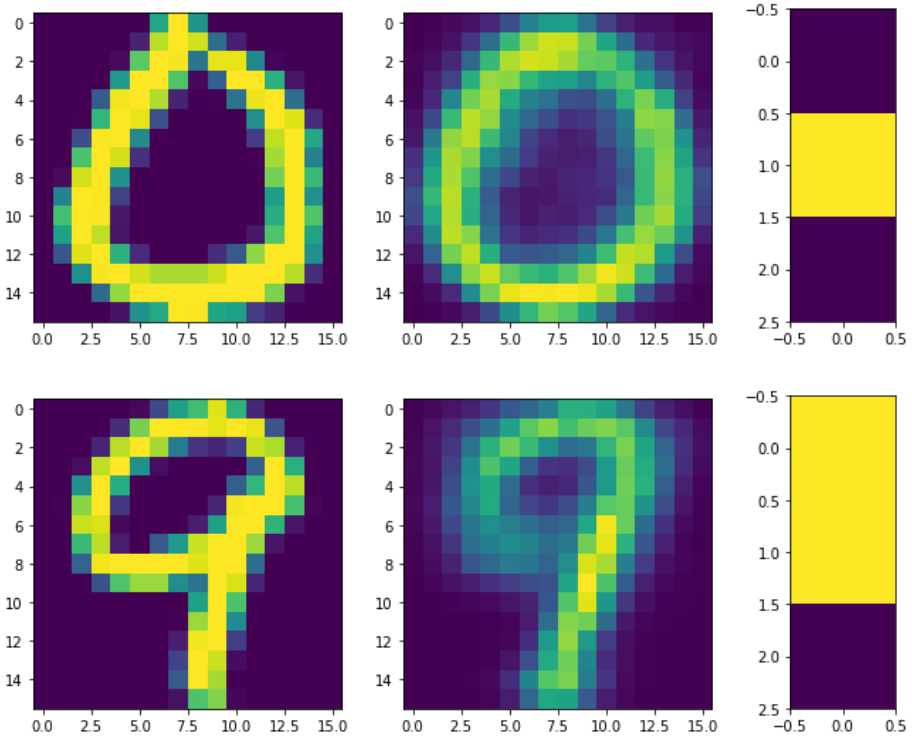

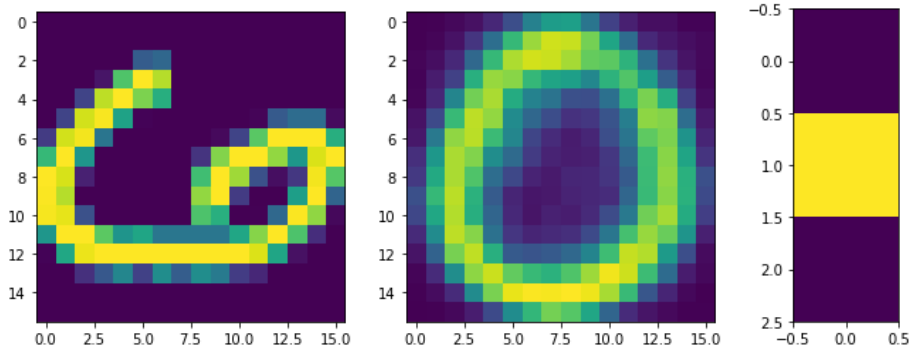

On observe le même comportement que dans la compression de taille 10 mais cette fois-ci la reconstruction et la compression de notre 6 et 0 sont complètement identiques, alors qu'on observait une différence majeure dans les reconstructions (et les compressions) précédentes.
Si on considère un codage binaire, il est intéressant de remarquer qu'un zéro est compresser à [0,1,0] alors que le 9 est compresser à [1,1,0]. Si on réalise un codage sur 3 bits (comme cela semble être le cas ici), il existe donc 8 possibilités, ce qui ne suffit pas à coder l'ensemble des chiffres.

6.1.3 Conclusion

On observe ici que plus notre facteur de compression est petit (donc la compression est forte), plus notre reconstruction est générale, ce qui est induit par l'information gardé par la compression. Dans le cas de nos 6 et 0, leur différentiation est perdu pendant la compression de taille 3 mais pas pour la taille 10, il y a donc une perte de l'information trop forte avec une compression de taille 3.
De plus on observe bien une compression proche quand les nombres se ressemblent (même si le 6 et le 0 ne sont pas les mêmes nombres, ils se ressemblent assez ici et notre compression était sûrement trop forte), ce qui peut permettre du clustering en reduisant fortement les dimensions, on en parlera dans une partie suivante.

6.2 T-SNE et 2 dimensions

Ici on va comparer le résultat obtenue en réalisant une compression à 2 valeurs et le T-SNE obtenue sur les mêmes données.

6.2.1 Observations

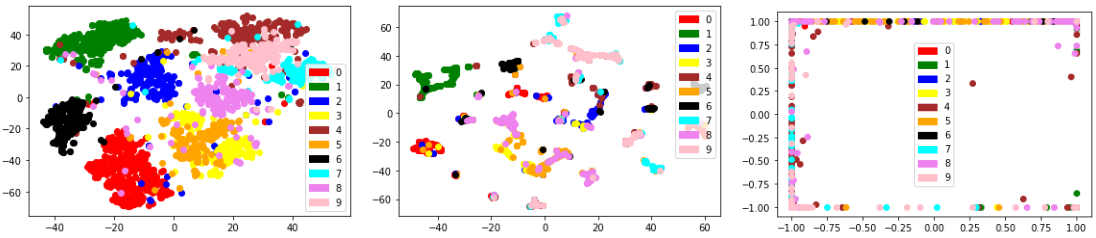

Ici, nous affichons 3 schémas, le premier est obtenue par T-SNE sur les données de test de base, le second est obtenue par T-SNE sur les données compressé en taille 10 et le dernier est obtenue par compression de taille 2.
On observe dans un premier temps que T-SNE arrive très bien à représenter les données en 2D, on observe facilement des nuages de couleurs différentes.
C'est toujours le cas dans notre deuxième schéma mais les nuages sont beaucoup plus concentrés mais cette fois-ci dans différentes zones pour une même classe, sûrement du à la compression de notre auto-encodeur.
Dans notre dernier schéma, les données semblent complètement jeté au hasard.
Nous avons essayé d'augmenter le nombre d'itérations en apprentissage mais cela ne semble pas améliorer

les résultats, il est quand même intéressant de remarquer que parfois on observe une meilleur répartition :

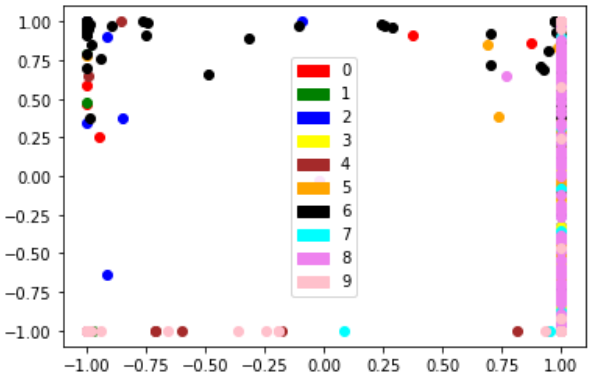

On observe ici une meilleurs répartition, les 8 par exemple sont tous à droite, les 9 en bas à gauche mais certains sont moins clair comme les 7 qui sont perdu dans les autres données, sûrement superposé avec les 8 (les données avec un certain nombre étant affiché dans l'ordre).

6.2.2 Conclusion

Les résultats obtenues après compression sont peu convainquant pour représenter les classes des données,l'auto-encodeur n'étant pas fait pour l'affichage des données en 2D à la différence de T-SNE.
L'effet principal de la compression est un rapprochement des points représentant le même nombre (et pas seulement malheureusement) la plus part du temps, ce qui rend plus difficile la prise en compte de la masse des données affiché, ainsi l'utilisation d'un auto-encodeur en pré-traitement pour la réduction de données ne permet pas vraiment d'améliorer les performances du T-SNE.
Mais il reste intéressant de remarquer que les informations permettant de définir un chiffre sont gardé dans les données avec une compression de taille 10 car T-SNE arrive à regrouper les données de même classe entre elles.

6.3 Clustering

Nous avons effectué un K-Means avec 10 points de départ pour arriver à trouver des clusters pour chaque nombre.

Pour tester nos clusters, nous avons utilisé la formule suivante pour calculer un score de pureté pour chaque cluster,

$$\text{Purity} = \frac{1}{N}\sum_{i=1}^{k}\max_{j}|c_i \cap t_j| \tag{1}$$

avec t_j la clase majoritaire d'un cluster.
Nous avons également calculé un randscore avec la fonction adjusted rand score de sklearn.

Voici les résultats obtenues sur le dataset USPS après compression de taille 10 par l'auto-encodeur :

Calcul du score de pureté sur les données compressés	
Clusters	Score
0	0.55
1	0.93
2	0.59
3	0.59
4	0.44
5	0.61
6	0.46
7	0.79
8	0.59
9	0.59
Pureté moyenne = 0.62	
Adjusted Rand score (SKlearn)	0.44

Si on essaye d'effectué un clustering sur les données non-compressés, on observe les résultats suivants :

Calcul du score de pureté sur les données non-compressés	
Clusters	Score
0	0.46
1	0.96
2	0.70
3	0.75
4	0.66
5	0.58
6	0.78
7	0.67
8	0.72
9	0.68
Pureté moyenne = 0.69	
Adjusted Rand score (SKlearn)	0.49

Voici les classes majoritaires de ces 2 différents clustering :

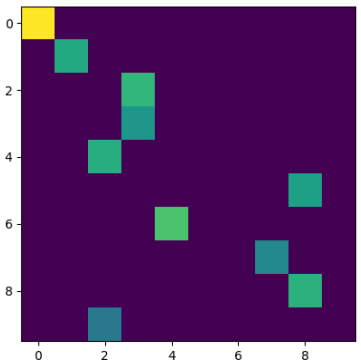

(a) Argmax sur les données compréssées

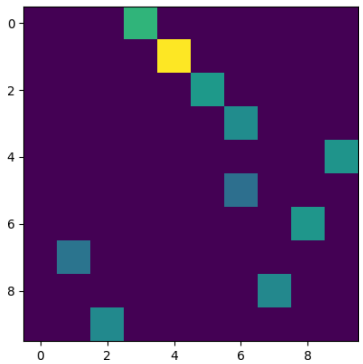

(b) Argmax sur les données originales

On observe bien des classes majoritaires différentes pour chaque cluster, mais 2 clusters ont la même classe majoritaire dans nos clusters après compression, ce qui indique sûrement une perte d'information

(ou une mauvaise initialisation mais cela ne semble pas être le cas car ce résultat arrive souvent).
Une pureté moyenne de 0.62 est nétemment supérieur à une purete issue de l'aléatoire, le rand score obtenue nous permet de confirmer cette idée, en effet le rand score est égal à 0 quand le clustering obtenues est complètement aléatoire et 1 si les clusters sont identiques à ceux attendus. On observe une perte faible de précision entres les données dans leur dimension d'origine et les données compréssés, mais par contre il est beaucoup moins coûteux à garder en mémoire.

7 Réseau convolutif

Nous avons implementé le réseau décrit dans le projet, nous avons entraîné nos réseaux sur des batch de taille 25 avec un pas de gradient de 1e-3 pour éviter de diverger. Les résultats obtenues sont les suivants :

Comparaison précision convolutif/linéaire		
nb iterations	precision conv	precision lineaire
10	0.891	0.850
100	0.916	0.906
1000	0.915	0.919

Le réseau "linéaire" comparé ici est le réseau présenté dans la partie **Mise en place du multi-classe**, nous utilisons une couche cachée de taille 128 ici.
La précision de notre réseau convolutionnel semble très proche de notre réseau multi-classe (sachant que moins on fait d'itérations plus la précision dépend des valeurs initiales).
Pour nous, 3 raisons sont possibles pour ce manque de différence de performances entre les 2 réseaux (alors qu'on s'attendait à une meilleur précision pour le réseau convolutionnnelle), notre réseau convolutionnel contient beaucoup de paramètres (407 496) par rapport à l'autre réseau (34 048), ce qui ralenti fortement la convergence et donc nécessite beaucoup plus de données ou d'itérations. Une autre possibilité est l'absence de convolution 2D ou vertical. Une dernière possibilité serait le sur-apprentissage, en effet on observe une loss de l'ordre de 10^{-5} avec 1000 itérations à la différence de notre réseau "lineaire" qui est de l'ordre de 10^{-3} (et cela expliquerais la perte de précision de 100 à 1000 itérations).
Pour en avoir le coeur net nous affichons déjà l'évolution de la loss dans nos 2 cas pour vérifier la convergence :

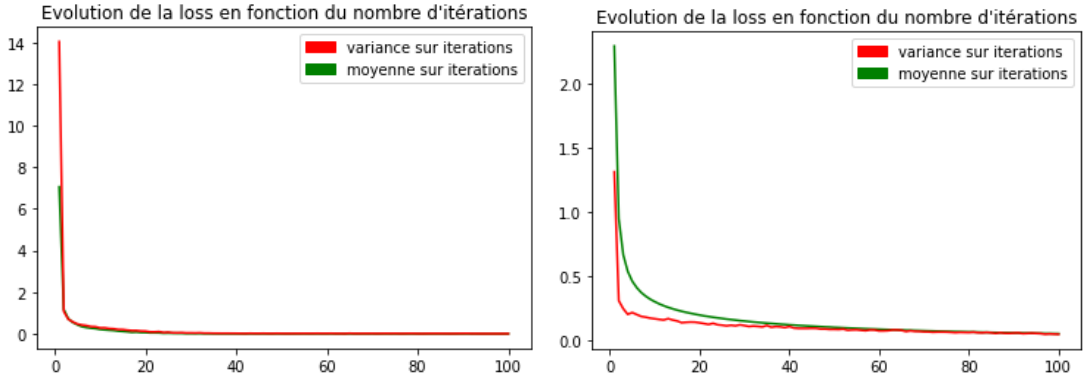

Il semble que les 2 réseaux converge bien même après 100 itérations, comme prévu (même si comme on la vu dans la partie **Réseau linéaire**, cela ne veut pas tout dire mais 1000 itérations devrait suffire ici).
Le temps de convergence ici n'est pas intéressant car il dépend beaucoup de l'initialisation.
Nous avons de plus vérifié que nos algorithmes ne soient pas en sur-apprentissage en utilisant un ensemble de validation, on utilisera 500 données pour vérifier à chaque itération la précision obtenue.
Voici les courbes obtenues :

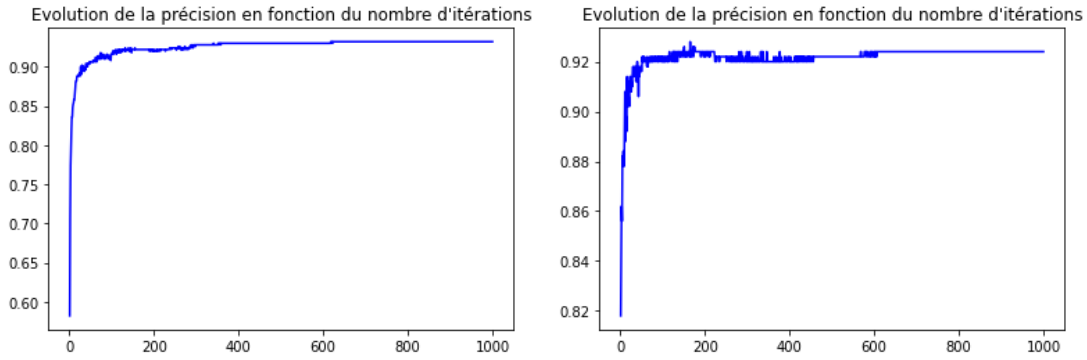

Il ne semble pas y avoir de sur-apprentissage même après 1000 itérations, le problème est donc sûrement du à l'absence de convolution 2D ou vertical.